유전 로보틱스를 통한 미로 찾기 로봇

[팀명] (대표 [이름], 팀원 [이름], [이름], [이름])

1. 연구의 요약

○ 연구 동기와 목적: 로봇의 행동 규칙을 사람이 설계하는 대신 신경망의 가중치를 유전자로 두고 유전 알고리즘으로 진화시키면(유전 로보틱스) 센서 값만으로 미로를 푸는 로봇을 얻을 수 있는지 확인하고, 시뮬레이션에서 얻은 최종 가중치를 소형 실제 로봇에 넣어 보는 것을 목적으로 한다.

○ 연구 내용: 웹 시뮬레이션에서 거리 센서 5개, 은닉 뉴런 6개, 바퀴 2개 출력으로 이루어진 신경망(유전자 50개)을 개체 100마리로 진화시켰다. 가장 단순한 방식에서 시작해 실패를 관찰하고 한 번에 한 가지씩 12단계로 개선했다(충돌 감점, 이동 거리, 탐험 보상, 재방문 감점, 도착 개체 우선 정렬, 자동 조절). 이어서 지름 약 11cm의 소형 원형 로봇(아두이노 나노, N20 모터, 거리 센서 5개)을 설계해 6×6칸 미로에서 시험할 준비를 했다.

○ 발견한 점: 진화는 훈련한 미로를 풀었다(반복 실험 128회 중 112회에서 도착, 84~91%). 그러나 평가 요소를 더한 방식 사이의 도착률 차이는 작아(84~91%) 한 번 실행에서 보였던 개선 일부는 반복 실험에서 재현되지 않았다. 훈련에서 도착한 개체를 훈련에 쓰지 않은 미로 100개에서 시험하면 평균 1.7%만 풀어(무작위 개체는 0%) 한 미로의 경로를 외운 해법임을 확인했다. 소형 실제 로봇 시험은 후속 과제로 남겼다.

2. 연구 동기 및 목적

2-1. 연구 동기

평소 로봇이 스스로 판단하고 움직이는 방식에 관심이 많았다. 그러던 중 로봇의 행동 규칙을 사람이 일일이 설계하는 대신, 신경망의 가중치를 생물의 유전자처럼 다루어 세대를 거치며 진화시키는 유전 로보틱스라는 분야를 알게 되었고 매우 흥미롭게 느꼈다. 규칙을 정해 주지 않아도 점수만으로 로봇이 스스로 행동을 찾아낸다는 점이 신기했고, 직접 확인해 보고 싶었다.

이를 확인할 문제로 미로 찾기를 선택했다. 미로는 로봇이 센서로 얻은 정보만으로 길을 찾아야 하고, 성공과 실패가 분명하며, 규칙이 단순해 시뮬레이션하기 쉬운 문제이기 때문이다. 다만 실제 로봇을 수백 세대 진화시키는 것은 시간과 비용이 크므로, 컴퓨터 시뮬레이션에서 로봇을 진화시킨 뒤 최종 가중치만 소형 로봇에 넣어 실제 미로에서 시험해 보기로 했다.

2-2. 연구 목적

신경망 가중치를 유전자로 두고 유전 알고리즘으로 진화시키는 유전 로보틱스 방법으로, 사람이 규칙을 설계하지 않고도 센서만으로 미로를 찾는 로봇을 얻을 수 있는지 확인하고, 이를 소형 실제 로봇에 적용하여 시뮬레이션과 현실의 차이를 분석한다.

1. 거리 센서 5개와 작은 신경망(유전자 50개)으로 이루어진 가상 로봇이 유전 알고리즘으로 10×10칸 미로를 통과하도록 진화시킨다.
2. 가장 단순한 평가 방식에서 시작해 실패를 관찰하고, 충돌 감점·이동 거리·탐험 보상 같은 평가 항목을 한 번에 하나씩 더하며 무엇이 왜 효과가 있었는지(또는 없었는지) 분석

한다.

3. 같은 방식이 미로에 따라 얼마나 다른 결과를 내는지 확인하여 방법의 한계와 일반화 가능성을 검토한다.
4. 시뮬레이션의 최종 가중치를 지름 약 11cm의 소형 로봇(아두이노 나노, N20 모터, 거리 센서 5개)에 넣어 6×6칸 실제 미로에서 시험해 볼 수도 있도록 준비하고, 시도할 경우 시뮬레이션 결과와 비교한다.

3. 이론적 배경 및 선행 연구

3-1. 이론적 배경

유전 알고리즘. 생물의 진화를 흉내 낸 탐색·최적화 방법으로 Holland가 이론적 틀을 세웠다[9]. 후보 해를 개체로 보고 개체의 정보를 숫자 배열인 유전자로 나타낸다. 개체마다 얼마나 잘했는지를 적합도(점수)로 매기고, 적합도가 높은 개체를 선택하여 두 개체의 유전자를 섞고(교차) 일부를 무작위로 바꾸어(돌연변이) 다음 세대를 만든다. 적합도가 높은 개체를 변경 없이 다음 세대에 그대로 넘기는 방식을 엘리트 보존이라 한다. 본 연구는 개체 100마리, 상위 20% 엘리트 보존, 한 점 교차, 돌연변이 확률 5%를 사용했다.

신경망. 입력 → 은닉층 → 출력으로 이어지는 계산 구조이다. 한 뉴런은 입력에 가중치(연결 세기)를 곱해 더하고 편향(기본값)을 더한 뒤 활성화 함수(본 연구는 tanh)를 거쳐 −1~1 사이 값을 출력한다. 일반적으로는 정답 데이터와의 오차를 줄이는 방향으로 가중치를 고치는 역전파로 학습한다[3]. 반면 진화 알고리즘으로 신경망의 연결 가중치, 구조, 학습 규칙 등을 탐색하는 접근을 신경 진화라 하며[4], 정답 행동을 정하기 어려운 로봇 제어에 쓰인다. 본 연구의 신경망은 입력 5, 은닉 6, 출력 2이며 가중치와 편향 50개가 유전자가 된다.

유전 로보틱스(진화 로봇공학). 로봇의 제어기를 진화 알고리즘으로 자동 설계하는 분야이다[11]. 실제 로봇에서 진화 전 과정을 수행한 초기 사례가 있으나[1] 시간이 오래 걸려, 시뮬레이션에서 진화시킨 뒤 실제 로봇으로 옮기는 경우가 많다. 이때 시뮬레이션과 현실의 차이를 현실 격차(reality gap)라 하며, 센서 잡음·바퀴 미끄러짐·배터리 전압 변화가 원인이다. 시뮬레이션에 잡음을 넣어 진화시키면 실제 로봇에서의 성능을 높일 수 있다는 연구가 있다[2].

목적 기반 탐색과 새로움 탐색. 적합도(목적)만 따라 탐색하면 목표에 가까워 보이지만 막다른 곳으로 이끄는 기만적 적합도에 빠져 지역 최적에 갇힐 수 있다. Lehman과 Stanley는 목적 대신 행동의 새로움만 보상하는 새로움 탐색이 미로 항해 실험에서 목적 기반 탐색보다 나은 결과를 냈다고 보고했다[5]. 본 연구의 탐험 보상(다른 개체가 가지 않은 칸을 방문하면 점수를 더함)은 이와 같은 방향의 요소이다.

로봇 구동과 센서. 두 바퀴를 따로 돌리는 차동 구동 방식은 두 바퀴 속도의 평균이 전진 속도, 차이가 회전 속도가 된다[10]. 거리는 비행시간(ToF) 센서로 잰다. 이 센서는 빛이 물체에 반사되어 돌아오는 데 걸린 시간으로 거리를 계산하며, 본 연구는 STMicroelectronics의 VL53L0X를 사용한다[12]. 이 센서는 I2C 통신을 하고 기본 주소(7비트 0x29)가 모두 같아, 여러 개를 쓰려면 XSHUT(하드웨어 정지) 핀으로 센서를 하나씩 켜면서 주소를 바꾸어야 한다[12].

추가 용어	뜻	출처

신경 진화	진화 알고리즘으로 신경망의 가중치·구조·학습 규칙을 찾는 방법	[4]
역전파	출력 오차를 줄이도록 은닉층까지 거꾸로 가중치를 고치는 신경망 학습법	[3]
현실 격차	시뮬레이션에서 잘 되던 제어기가 실제 로봇에서 성능이 떨어지는 현상	[2]
기만적 적합도	적합도가 높아지는 방향이 실제 목표로 이어지지 않아 탐색이 막히는 상황	[5]
새로움 탐색	목표 달성 정도 대신 지금까지 보지 못한 새로운 행동을 보상하는 탐색	[5]
엘리트 보존	상위 개체를 변경 없이 다음 세대에 넘겨 최고 기록이 퇴보하지 않게 함	[9]
차동 구동	좌우 바퀴 속도 차이로 방향을 바꾸는 이동 방식	[10]
I2C / XSHUT	센서가 하나의 통신선을 나눠 쓰는 방식 / 센서를 켜고 끄는 핀	[12]

3-2. 선행 연구

유전 로보틱스와 미로 탐색에서 알려진 문헌을 정리했다(출판 정보는 제출 전 원문으로 다시 확인해야 한다).

문헌	내용	본 연구와의 관계
Holland(1975) [9]	유전 알고리즘의 기초 이론	선택·교차·돌연변이의 기본 구조를 사용
Braitenberg(1984) [10]	센서를 바퀴에 직접 연결해도 복잡해 보이는 행동이 나옴	센서→바퀴의 단순한 구조를 신경망으로 확장
Floreano & Mondada(1994) [1]	실제 Khepera 로봇에서 진화 전 과정을 돌려 장애물 회피 행동을 얻음	본 연구는 시뮬레이션에서 진화한 뒤 가중치만 이식
Jakobi 외(1995) [2]	시뮬레이션에 잡음을 넣으면 실제 로봇으로 옮겼을 때의 성능이 좋아짐	본 연구는 잡음 없이 진화 → 후속 과제
Lehman & Stanley(2011) [5]	목적 대신 새로움만 보상하는 탐색이 미로 항해에서 목적 기반 탐색보다 우수	“남이 안 간 칸이면 보상”을 더하자 미로 3이 풀린 본 연구 결과와 방향이 같음
Shorten & Nitschke(2015) [6]	신경 진화로 미로를 푸는 제어기를 만들고 점수 방식·새로움 탐색·혼합 방식을 비교. 새로움 탐색과 혼합 방식이 더 어려운 미로에서 일반화되는 제어기를 더 많이 만듦	본 연구는 아직 처음 보는 미로에서의 일반화를 재지 못함
arXiv 1904.06239(2019) [13]	차동 구동 로봇이 실내 미로에서 길을 찾도록 NEAT에 GRU를 더해 진화(환경 209개에서 I-Bug보다 좋은 결과)	구조까지 진화시키는 방식. 본 연구는 구조를 고정하고 가중치만 진화
오동화(2016) [8]	게임 환경에서 미로를 만들고 유전 알고리즘과 인공신경망으로 경로 탐색. 미로가 커지면 유전 알고리즘 단독은 무작위로 수렴	미로가 커질수록 어려워지는 점이 본 연구와 이어짐(실제 로봇은 아님)

김대진·강대성(2000) [7]	Khepera의 재귀 신경망 제어기를 진화와 학습을 함께 써서 설계, 진화만 쓴 경우보다 충돌 회피 우수	본 연구는 진화만 사용. 학습 결합은 후속 과제

국내 선행 연구는 추가 조사하여 보완한다.

4. 연구 과정 및 방법

4-1. 연구 과정

실험 환경과 용어

실험은 컴퓨터 속 가상 미로에서 로봇 100대가 동시에 출발하는 방식으로 진행했다. 미로는 한 변 10칸, 한 칸 20cm이고 오른쪽 위 칸에서 출발해 왼쪽 아래 칸에 들어가면 성공이다. 로봇은 지름 8cm의 원이며 로봇이 향한 방향 기준 왼쪽, 왼쪽 앞, 앞, 오른쪽 앞, 오른쪽의 벽까지 거리(최대 40cm)를 재는 센서 5개를 가진다. 100대가 40초 동안 움직이면 한 세대가 끝나고 점수가 높은 로봇을 바탕으로 다음 세대 100대를 만든다.

용어	뜻
개체 / 유전자	개체는 가상 로봇 한 대이며, 신경망 가중치와 편향 50개의 숫자가 그 개체의 유전자이다
세대 / 적합도	세대는 100대가 한 번 달리고 점수를 받는 한 회차, 적합도는 한 대가 얼마나 잘했는지 나타내는 점수이다
시드(미로 번호)	미로를 만드는 난수의 번호. 같은 번호이면 같은 미로와 같은 처음 로봇이 만들어져 결과를 재현할 수 있다. 본 연구는 1, 2, 3, 26, 67번으로 실험했다
도착 / 충돌	도착은 로봇 중심이 목표 칸에 들어가는 것, 충돌은 몸체가 벽과 겹쳐 밀려나는 것(0.05초마다 판정)이다
칸 단위 최단 경로	출발 칸에서 목표 칸까지 벽을 통과하지 않고 가는 최소 칸 수 × 20cm. 로봇은 모서리를 자를 수 있어 이보다 짧은 기록도 나온다
탐험 보상	도착하지 못한 로봇이 다른 로봇이 가지 않은 칸을 방문하면 점수를 더해 주는 요소
재방문 / 정체	재방문은 이미 지난 칸에 다시 들어가는 것, 정체는 최고 기록이 여러 세대 동안 거의 나아지지 않는 상태이다
순위 역전 / 도착 개체 우선 정렬	순위 역전은 도착하지 못한 로봇의 점수가 도착한 로봇보다 높아지는 현상, 우선 정렬은 도착한 로봇을 점수와 관계없이 항상 위에 두어 부모로 보존하는 방식이다

4-1-1. 연구 진행 일정

본 연구는 완성된 알고리즘을 한 번에 설계하지 않고, 가장 단순한 방식에서 시작해 실패를 관찰하고 문제를 하나씩 개선하는 순서로 진행했다. 알고리즘은 개체(센서·신경망·움직임), 평가(적합도 계산), 진화(선택·교차·돌연변이)의 세 부분으로 나누어 각 단계에서 어느 부분을 바꾸었는지 구분했고, 개선할 때마다 이전 방식은 수정하지 않고 보존했다.

(1) 기본 방식의 설정 (단계 1~3: 개체)

단계 1. 칸 단위로 이동하고 벽의 유무(0 또는 1)를 알려 주는 센서 4개를 사용했으며 적합도는 종료 위치와 목표 사이 직선거리에 음의 부호를 붙인 값($f = -d$)으로 했다. 약 50세대까지 도착 개체가 없었고 최고 개체도 벽에 막혀 정지했다. 벽의 유무만 알려 주는 센서는 정보량이 부족하다고 판단했다.

단계 2. 연속 이동과 로봇이 향한 방향 기준 거리 센서 5개, 두 바퀴 출력으로 개체를 바꾸었다. 25세대까지는 도착이 없었으나 40세대에 미로 1, 2, 3 모두에서 도착 개체(44~70마리)가 나타났다. 이후 모든 실험은 이 방식을 기본으로 했다.

단계 3. 센서 배치의 영향을 보기 위해 상하좌우 방향이 고정된 센서 4개와 4방향 이동 방식을 추가했다. 이 방식은 25세대 동안 최고 적합도가 변하지 않았고 벽 충돌이 733회였다. 센서와 이동 방식이 함께 달라 센서만의 우열로 해석하지 않았다.

(2) 적합도 계산식의 개선 (단계 4~12: 평가, 단계 9는 평가·진화)

단계	변경한 적합도 계산식	변경 사유	관찰 결과
4	벽에 부딪힌 횟수 b에 감점 p를 곱해 감산	벽에 반복 충돌하며 이동하는 개체가 다수	감점 0.5~1.0에서 충돌 거의 없이 도착(미로 1), 감점 0.2는 미로 1·3에서 도착 못함
5	도착 개체는 200 − (이동 거리 가중치 × 이동 거리 L)	도착해도 우회 경로가 김	미로 1의 이동 거리 570→466cm, 도착 개체 수는 감소
6	충돌 감점과 이동 거리를 병용	두 요소를 함께 썼을 때의 영향 확인	미로에 따라 감점 0.2와 0.5의 우열이 반대, 미로 3은 모두 실패
7	목표와 가까운 칸에 가중한 탐험 보상 N 추가(단계 2에서 분기)	막다른 구역에 갇힌 개체가 탈출하지 못함	순위 역전 발생, 미로 26·3에서 도착 감소
8	충돌 감점·이동 거리·탐험 보상을 하나로 통합	이전 기능을 누적하기 위함	미로 26에서 충돌 5회로 감소, 미로 3은 실패
9	도착 개체를 점수와 관계없이 상위 정렬, 도착 후 탐험 보상 종료와 재방문 감점 r 적용	순위 역전과 도착 후 불필요한 탐험	미로 26·1·2에서 도착 개체 증가, 미로 3은 변화 없음
10	탐험 보상에서 “목표에 가까운 칸” 조건 제거	보상이 목표 근처 막다른 구석에 편중된 것으로 추정	미로 3이 30세대에 처음 도착
11	도착 후 최단 이동 거리가 정체되면 이동 거리 배율 m을 단계적으로 증가	도착 후 경로가 더 짧아지지 않음	미로 26의 최소 이동 682→524cm, 나머지는 거의 변화 없음
12	탐험 보상 상한 해제, 충돌 감점의 자동 조절	가중치를 사람이 정하지 않고 진행 상태에 맞춰 조절하는 방식의 효과 확인	미로 26만 개선, 미로 1·67은 도착 못함, 미로 2·3은 악화

단계 7은 단계 6이 아니라 단계 2의 기본 방식에서 분기했고 단계 8에서 앞의 요소를 모두 통합했다. 위 표의 관찰 결과는 미로·방식당 1회 실행한 값이며, 반복 실험(5-1-1)에서 일부는 재현되지 않았다. 12단계 중 개체를 바꾼 단계는 2, 3이고 진화(정렬 방식)를 바꾼 단계는 9이며 나머지는 모두 평가(적합도 계산식)의 개선이다. 최종 단계(단계 12)의 적합도는 다음과 같다.

미도착 개체: $f = -d - p \cdot b + w_{탐험} \cdot N$

도착 개체: $f = 200 - w_{거리} \cdot m \cdot L - p \cdot b - r \cdot R$

기호	이름	정의 및 값
f	적합도	개체의 우수성을 나타내는 점수. 클수록 부모로 선택될 가능성이 높다
d	종료 거리	종료 시점(미도착은 40초 경과 시점)에서 로봇 중심과 목표 칸 중심 사이의 직선거리(cm)
b, p	충돌 횟수, 충돌 감점	제어 주기(0.05초)마다 몸체가 벽과 겹쳐 밀려난 횟수, 1회당 감점(기본 0.2). 단계 12에서는 진행 상태에 따라 0~0.6으로 자동 변화
N	새로움 점수	개체가 방문한 각 칸에 대해 그 칸을 방문한 개체 수의 역수를 합한 값. 소수의 개체만 가 본 칸을 방문할수록 커진다(단계 7~9는 칸마다 “목표와 가

		까운 정도” 곱함)
w탐험	탐험 보상 가중치	0에서 시작해 최단 거리가 5세대 동안 3cm 넘게 줄지 않으면 최댓값(기본 10, 단계 12는 100)의 1/4씩 증가, 거리가 줄면 0으로 복귀. 도착 개체에는 부여하지 않음
L, w거리, m	이동 거리, 가중치, 배율	도착 개체의 실제 이동 거리(cm), 이동 거리 가중치(0.1), 최소 이동 거리가 5세대 동안 5cm 넘게 줄지 않으면 1씩 증가하는 배율(1~9)
R, r	재방문 횟수, 재방문 감점	이미 지난 칸에 다시 들어간 횟수, 1회당 감점(1). 도착 개체가 처음 나온 다음 세대부터 적용
200	도착 기본 점수	도착한 개체가 미도착 개체보다 항상 높은 점수를 갖도록 하는 기준값

(3) 실제 로봇 적용을 위한 준비

① 제작 가능한 크기의 현실용 설정(6×6칸 미로, 칸 25cm, 로봇 지름 11cm)을 추가했다. 기존 연구용 설정(10×10칸)은 바꾸지 않았고 동일 조건(미로 1, 25세대)에서 이전과 같은 결과가 재현됨을 확인했다.

② 소형 원형 로봇을 설계하고 부품을 선정했다(아두이노 나노, N20 모터와 지름 34mm 바퀴, TB6612 모터 드라이버, VL53L0X 센서 5개, AAA 전지 3개와 5V 승압 모듈). 구상도와 배선도를 작성했다(그림 1, 2).

③ 6×6칸 미로 시드 1~400 중 최단 경로 16칸 이상, 막다른 길 6개 이상, 최단 경로상 갈림길 4개 이상인 38개를 골랐다(상위 후보: 시드 365, 350, 80, 178).

④ (예정) 후보 시드에서 현실용 설정으로 학습시켜 도착 여부를 확인하고 최종 가중치를 정한다. ⑤ (예정) 로봇을 제작하고 센서 주소 설정, 신경망 계산, 모터 제어 펌웨어를 작성한다. ⑥ (예정) 실제 미로에서 시험하고 시뮬레이션 결과와 비교한다.

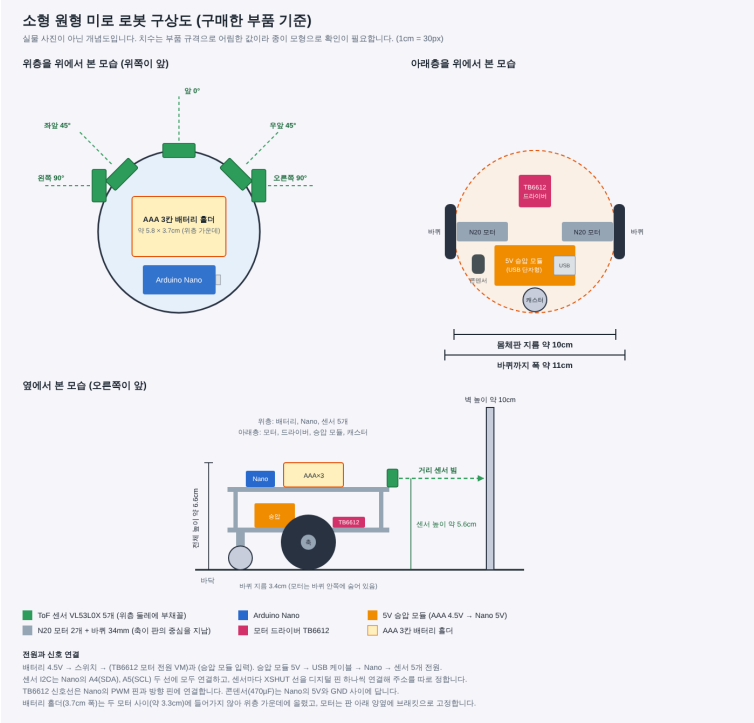


그림 1. 소형 원형 로봇 구상도(위층·아래층·옆면)

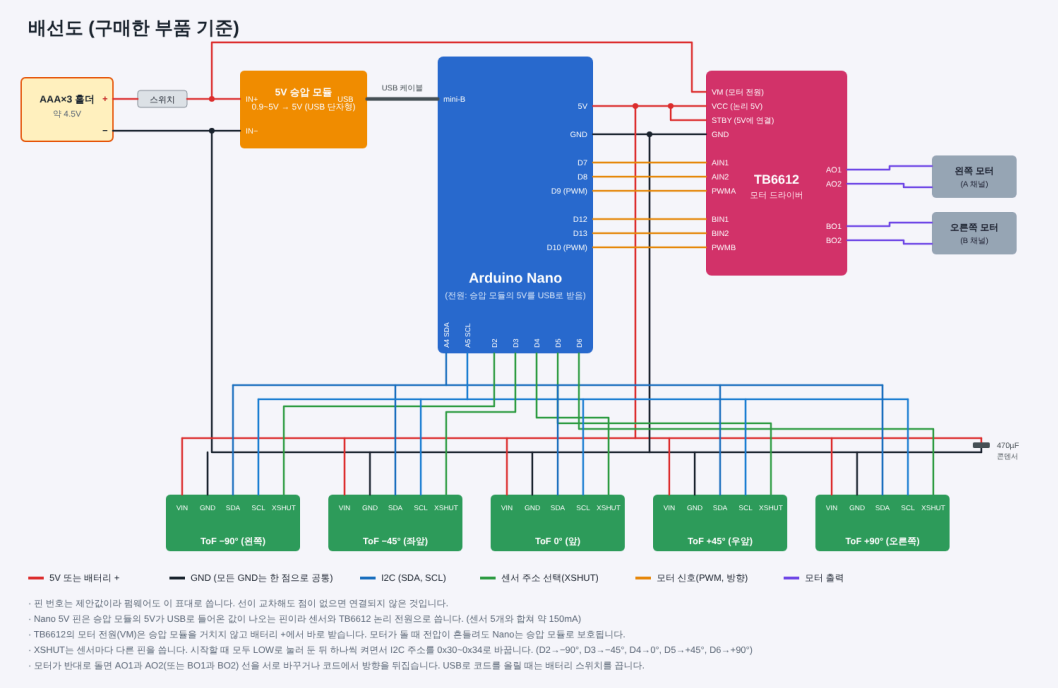


그림 2. 배선도(전원, 승압 모듈, 나노, 모터 드라이버, 거리 센서 5개)

4-2-1. 가설 설정, 실험설계 및 과정, 분석방법, 시행착오 극복

① 가설 설정

1) 신경망 가중치를 유전자로 쓰는 유전 알고리즘만으로, 미로 규칙을 정해 주지 않아도 거리 센서만 보는 로봇이 미로를 통과하도록 진화한다.
2) 점수(적합도)에 보상·감점 항목을 한 번에 하나씩 더하면 풀리는 미로가 늘고 도착 경로가 짧아진다.
3) 한 미로에서 훈련한 최고 개체는 처음 보는 미로에서도 길을 찾는다(일반화).
4) 시뮬레이션에서 얻은 최종 가중치를 같은 센서 배치의 소형 실제 로봇에 넣어도 훈련한 미로에서는 비슷하게 동작할 수도 있다(시도해 볼 수도 있으나 이번 연구에서 확인하지 못했다).

② 실험 설계 및 과정

신경망. 로봇의 행동은 하나의 신경망이 결정한다. 입력은 센서 5개의 거리를 최대 측정 거리 40cm로 나눈 0~1의 값, 은닉 뉴런은 6개, 출력은 왼쪽·오른쪽 바퀴 속도(−1~1)이다. 뉴런은 입력에 가중치를 곱해 합하고 편향을 더한 뒤 tanh를 적용한다.

은닉 $h_j = \tanh(\Sigma w_{ij} \cdot x_i + b_j)$, 출력 $o_k = \tanh(\Sigma v_{jk} \cdot h_j + c_k)$

유전자 수 = 5×6 + 6 + 6×2 + 2 = 50

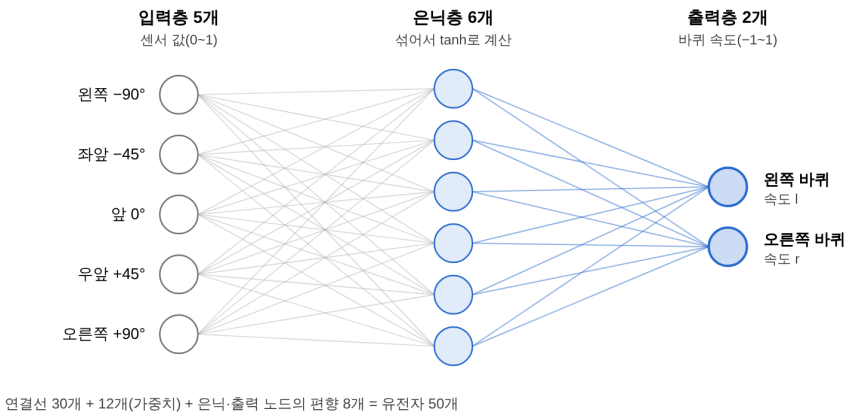


그림 3. 신경망 구조(입력 5, 은닉 6, 출력 2)

계산 예(설명용 가상 값): 센서 값 x = (0.9, 0.7, 0.2, 0.7, 0.9)(앞 센서 0.2는 약 8cm 앞에 벽), 한 은닉 뉴런의 가중치 (0.5, −0.3, −1.2, 0.4, 0.1)와 편향 0.1이면 $0.9\times0.5+0.7\times(-0.3)+0.2\times(-1.2)+0.7\times0.4+0.9\times0.1+0.1 = 0.47$이므로 $h = \tanh(0.47) \approx 0.44$이다. 출력 l = 0.41, r = −0.86이 나왔다면 전진 속도 $(l+r)/2\times30 \approx -6.8$cm/s, 회전 속도 $(l-r)\times30/8 \approx 4.8$rad/s로 로봇은 약간 후진하며 오른쪽으로 빠르게 회전한다(최고 속도 30cm/s, 바퀴 간격 8cm). 이 계산을 0.05초마다 최대 800회(40초) 반복한다.

적합도 지정. 개체 100개를 같은 미로의 출발 칸에서 동시에 출발시켜 최대 40초 움직이게 하고, 최초의 적합도는 종료 위치와 목표 칸 중심 사이의 직선거리 d(cm)에 음의 부호를 붙인 f = −d로 정의했다. 목표 칸에 진입하면 도착으로 판정해 그 자리에서 멈춘다. 적합도는 정답 행동을 알려 주지 않고 결과의 우수성만 나타낸다.

우수 유전자 선택과 돌연변이. 적합도 상위 20%(20개체)를 부모로 삼아 유전자를 변경 없이 다음 세대에 그대로 넘긴다. 나머지 80개체는 부모 둘을 무작위로 골라 유전자 50개를 임의의 한 지점에서 자르고 앞부분은 한 부모, 뒷부분은 다른 부모에서 가져와 만들며(한 점 교차), 자식 유전자의 각 원소에 5% 확률로 평균 0, 표준편차 0.5의 난수를 더한다(돌연변이). 이 과정을 100~250세대 반복한다. 처음 개체의 유전자는 평균 0, 표준편차 1의 난수로 만든다.

적합도 계산식의 단계적 변경. 신경망 구조와 진화 규칙은 고정하고 적합도 계산식만 바꾸며 영향을 비교했다. 이전 단계에서 본 문제를 근거로 요소를 한 번에 하나씩만 더하거나 고치고, 이전 방식은 수정하지 않고 보존하며, 결과가 나빠져도 값을 임의로 고치지 않고 그대로 기록했다. 단계별 내용은 4-1-1에 기술했다.

변인 통제. 신경망 구조, 개체 수 100, 상위 20% 보존, 한 점 교차, 돌연변이 5%(크기 0.5), 로봇 크기·최고 속도(30cm/s)·센서 개수와 측정 범위, 제어 주기 0.05초, 한 세대 40초, 출발·도착 위치를 모든 실험에서 같게 했다. 난수열은 시드로 고정해 같은 번호에서는 같은 미로와 같은 처음 개체가 나오게 했다. 독립변인은 평가 방식(단계 1~12), 미로 번호(1, 2, 3, 26, 67), 감점·보상 가중치이고 종속변인은 마지막 세대의 도착 개체 수, 첫 도착 세대, 도착 개체의 최소 이동 거리, 충돌 횟수이다.

③ 분석 방법

세대마다 도착 개체 수, 최고 개체의 목표까지 거리, 충돌 횟수, 이동 거리를 기록해 단계별·미로별로 비교했다. 도착 개체의 이동 거리는 칸 단위 최단 경로와 비교했다. 미로마다 방

식당 1회씩 실행했으므로 작은 차이는 유의한 차이로 해석하지 않았고, 수치로 직접 본 결과(확인)와 원인을 분리해 검증하지 못한 해석(추정)을 구분해 기술했다.

④ 시행착오와 극복

문제	원인	해결
단계 1에서 50세대까지 도착 없음	칸 단위 이동과 벽 유무 센서는 정보가 부족	연속 이동과 방향 기준 거리 센서 5개로 변경(단계 2)
탐험 보상 후 도착 개체보다 미도착 개체의 점수가 높아짐(미로 26, 50세대: −5.5 대 −9.4)	탐험 보상이 도착 보상을 넘음	도착 개체를 점수와 관계없이 위에 정렬(단계 9)
미로 3이 1회 실행에서 120세대까지 풀리지 않음	보상이 목표 근처 막다른 구석에 쏠린 것으로 추정(미확인)	“목표와 가까움” 조건 제거(단계 10)로 30세대에 풀렸으나, 반복 실험에서는 단계 9도 8회 중 5회 도착해 난수의 영향일 수 있음
단계 12가 1회 실행에서 일부 미로에서 악화	도착 뒤 충돌 감점이 0.6까지 올라 이동 거리보다 크게 작용한 것으로 추정	값을 임의로 고치지 않고 결과를 그대로 기록하고 반복 실험으로 재확인(도착률은 낮지 않았고 미로 3에서 첫 도착이 늦고 경로가 길었음)
연구용 미로(10×10칸, 20cm)는 실제로 만들기에 큼	실제 미로와 로봇을 만들 수 없는 크기	연구용 설정은 두고 현실용 설정(6×6칸, 25cm, 지름 11cm) 추가

5. 연구 결과 및 고찰

5-1-1. 연구 과정 요약, 실험 결과 및 연구 결론

연구 과정 요약. 가장 단순한 방식(단계 1)에서 시작해 단계마다 한 가지 요소만 더하며 12단계까지 올렸다. 처음에는 미로·방식당 1회씩 실행해 비교했고, 이 결과가 난수에 얼마나 좌우되는지 확인하기 위해 같은 설정에서 난수만 바꿔 8회씩 반복했으며(반복 실험), 훈련한 개체가 처음 보는 미로에서도 푸는지 시험했다(일반화 시험).

(1) 1회 실행 결과. 단계 8~12를 미로 5개에서 1회씩 실행했다(단계 8~11은 120세대, 단계 12는 150세대). 각 칸은 “마지막 세대의 도착 개체 수(첫 도착 세대)”이다. 미로 67은 단계 8, 9, 11을 실행하지 않았다.

미로	단계 8	단계 9	단계 10	단계 11	단계 12
26	34 (20)	43 (20)	32 (15)	33 (15)	46 (7)
1	27 (57)	34 (57)	32 (67)	34 (67)	0 (없음)
2	40 (7)	49 (7)	49 (7)	45 (7)	46 (7)
3	0 (없음)	0 (없음)	28 (30)	29 (30)	2 (113)
67	-	-	0 (130세대)	-	0 (없음)

미로 67은 단계 10에서 탐험 보상 최댓값을 기본값 10 대신 30으로 설정하면 약 91세대에 목표까지 거리가 74cm에서 60cm 아래로 내려가 정체를 벗어났고 152세대에 처음 도착했다(250세대에 28마리).

(2) 반복 실험. 단계 9, 10, 11, 12를 미로 26, 1, 2, 3에서 난수만 바꿔 8회씩(총 128회, 120세대) 실행했다. 각 칸은 “도착한 횟수 / 8 (첫 도착 세대의 중앙값)”이다.

미로	단계 9	단계 10	단계 11	단계 12

26	6/8 (17)	6/8 (15.5)	6/8 (15.5)	8/8 (12.5)
1	8/8 (10.5)	8/8 (10.5)	8/8 (10.5)	6/8 (7)
2	8/8 (10.5)	8/8 (10)	8/8 (10)	7/8 (10)
3	5/8 (17)	6/8 (16.5)	6/8 (16.5)	8/8 (38)
전체	27/32 (84%)	28/32 (88%)	28/32 (88%)	29/32 (91%)

도착한 실행에서 가장 짧은 이동 거리의 중앙값(cm)은 아래와 같다(칸 단위 최단 경로는 미로 26: 560, 미로 1: 440, 미로 2: 400, 미로 3: 560).

미로	단계 9	단계 10	단계 11	단계 12
26	535	567	574	548
1	427	427	434	411
2	435	378	349	459
3	530	579	564	682

(3) 처음 보는 미로 시험. 훈련에서 도착한 실행 112개의 최고 개체를, 훈련에 쓰지 않은 미로 100개(최단 경로 18~46칸, 평균 23.9칸)에서 한 번씩 시험했다. 비교 기준으로 무작위 개체 100개를 같은 미로 100개에서 시험했다(10,000회).

방식	실행 수	새 미로 100개 중 성공 평균
단계 9	27	1.5개 (중앙값 1, 최대 10)
단계 10	28	1.6개 (중앙값 1, 최대 6)
단계 11	28	1.8개 (중앙값 1, 최대 7)
단계 12	29	1.9개 (중앙값 2, 최대 5)
전체 / 무작위 개체	112 / 100개 개체	1.7% / 0%(10,000회 중 0회)

실험 결과에서 알아낸 것.

○ 확인: 훈련한 미로를 푸는 개체는 평가 방식과 상관없이 대부분의 반복에서 진화했다(128회 중 112회, 84~91%). 방식 사이의 차이는 32회 표본에서 크지 않았다.

○ 확인: 훈련한 개체는 처음 보는 미로를 거의 풀지 못했다(평균 1.7%, 무작위 개체 0%). 이 결과는 방식과 관계없이 일관되었다.

○ 확인: 1회 실행에서 “미로 3이 단계 10에서 처음 풀렸다”고 보였던 결과는 반복 실험에서 재현되지 않았다(단계 9도 5/8, 단계 10은 6/8 도착). 1회 실행의 방식 간 차이 일부는 난수의 영향이었다.

○ 확인과 추정: 자동 조절(단계 12)은 도착률이 낮지 않았으나(29/32) 미로 3에서 첫 도착이 늦고(중앙값 38세대) 경로가 길었다(682cm). 도착 뒤 충돌 감점이 오른 영향으로 보이나 원인을 분리하지는 못했다(추정). 탐험 가중치를 75~100까지 올린 1회 실행에서는 목표까지 거리가 오히려 멀어지는 구간이 있었다.

○ 확인: 도착한 개체의 이동 거리가 칸 단위 최단 경로에 가깝고(미로 1: 411~434cm, 최단 440cm) 새 미로에서 거의 실패하므로, 진화한 해법은 훈련한 미로의 경로를 외운 것이다.

현실용 미로와 실제 로봇. 6×6칸 현실용 미로에서 최단 경로가 16칸 이상이고 막다른 길과 갈림길이 많은 시드를 1~400 중에서 찾았다(조건 충족 38개, 상위 후보 365, 350, 80,

178). 일반화가 되지 않으므로 실제 로봇 시험은 학습에 쓴 그 미로에서만 의미가 있다. 이 시드에서의 학습과 실제 시험은 하지 못했으며, 해 볼 수도 있는 후속 과제로 남긴다.

항목	결과
현실용 설정에서 학습 결과(후보 시드별 도착 여부)	[시도하면 기입]
실제 로봇 성공 횟수 / 시도 횟수	[시도하면 기입]
시뮬레이션과 실제의 경로·소요 시간 차이	[시도하면 기입]

연구 결론.

1) 가설 1 지지: 거리 센서만 보는 작은 신경망(유전자 50개)을 유전 알고리즘으로 진화시키면, 규칙을 설계하지 않고도 훈련한 미로를 푸는 로봇이 반복 실험의 84~91%에서 나왔다. 벽의 유무만 아는 센서(단계 1)로는 도착 개체가 나오지 않아 센서의 정보량이 전제 조건이다.
2) 가설 2 지지되지 않음: 평가 항목을 더한 방식(단계 9~12) 사이에서 도착률 차이는 작았고(84~91%), 1회 실행에서 보였던 개선 일부는 반복 실험에서 재현되지 않았다. 다만 도착 개체를 점수와 무관하게 우선 정렬하면 순위 역전이 사라지는 것은 단계 9 이후 관찰되었다.
3) 가설 3 지지되지 않음(일반화): 훈련한 개체는 처음 보는 미로 100개 중 평균 1.7개만 풀어 한 미로의 경로를 외운 해법임을 확인했다. 평가 방식을 바꾸는 것만으로는 이 한계가 달라지지 않았다.
4) 실제 로봇 적용은 시도해 볼 수도 있으나 이번 연구에서 확인하지 못했다. 일반화가 되지 않으므로 학습한 미로에서만 시험하는 것이 의미 있다.
5) 의의와 후속 연구: 단계별 기록과 반복·일반화 시험으로 “훈련한 미로를 푸는 것”과 “미로를 푸는 방법을 얻는 것”이 다름을 보였다. 여러 미로로 번갈아 훈련하는 방식이 다음에 확인할 핵심 과제이다.

5-2-1. 국내외 연구 사례와의 비교 분석

로봇의 신경망 제어기를 진화시키는 연구는 많다. 미로 주행·장애물 회피와 직접 관련된 사례를 검색으로 찾아 본 연구와 비교했다(세부 수치와 방법은 원문을 확인해 보완해야 한다).

연구	대상과 방법	본 연구와의 비교
Shorten & Nitschke(2015) [6]	신경 진화로 미로 제어기 생성, 점수 방식·새로움 탐색·혼합 비교. 새로움 탐색과 혼합 방식이 더 큰 미로에 일반화되는 제어기를 더 많이 만듦	새로운 칸 보상을 더한 방식이 1회 실행에서 미로 3을 풀었으나 반복 실험에서는 재현되지 않아 비교 결론은 보류. 일반화는 본 연구가 재어 보니 1.7%로 낮음
arXiv 1904.06239(2019) [13]	차동 구동 로봇의 실내 미로 주행을 NEAT+GRU로 진화(환경 209개)	구조까지 진화. 본 연구는 구조를 고정해 변인을 줄임
Floreano & Mondada(1994) [1]	실제 Khepera 로봇에서 진화 전 과정을 사람 개입 없이 수행	본 연구는 시뮬레이션 진화 후 가중치만 이식. 시뮬레이션과 현실의 차이 확인 필요
오동화(2016) [8]	게임 환경에서 미로를 만들어 유전 알고리즘과 신경망으로 경로 탐색	미로가 커질수록 어려운 점이 본 연구와 이어짐. 실제 로봇은 아님

김대진·강대성(2000) [7]	Khepera 재귀 신경망 제어기를 진화와 학습을 함께 써서 설계	본 연구는 진화만 사용. 학습 결합은 후속 과제

비교를 통해 알 수 있는 점은 다음과 같다. 첫째, 새로움을 보상하는 방향은 선행 연구와 같으나 본 연구의 반복 실험에서는 그 효과가 확인되지 않았다. 둘째, 선행 연구는 여러 미로에서 성능을 재는 일반화를 중심에 두는데 본 연구의 시험에서는 처음 보는 미로에서 평균 1.7%만 풀어 일반화가 되지 않았다. 셋째, 시뮬레이션에서 진화해 실제 로봇으로 옮기는 점이 차별점이자 위험 요소이며, 센서 잡음과 바퀴 미끄러짐을 학습에 넣지 않았으므로 실제 시험을 해 볼 수도 있으나 이번 연구에서는 하지 못했다. 넷째, 완성된 결과가 아니라 단계마다의 실패와 부작용(순위 역전, 보상 쏠림, 자동 조절의 악화)을 기록한 것이 본 연구의 특징이다.

5-2-2. 기대 효과

1) 교육적 효과: 유전 알고리즘·신경망·로봇 제어를 하나의 프로젝트로 엮어 학생 수준에서 재현할 수 있는 웹 시뮬레이터와 제작 절차를 제공한다.
2) 실패 기록의 가치: 점수 항목을 하나씩 더할 때 생기는 부작용을 기록해 후속 연구자가 같은 시행착오를 줄일 수 있다.
3) 저비용 실제 적용: 시뮬레이션에서 얻은 가중치만 로봇에 넣으므로 실제 로봇을 수백 세대 돌리지 않아도 되고, 부품도 아두이노 나노와 N20 모터 같은 저렴한 것(10만 원 안쪽)을 쓴다.
4) 후속 연구의 출발점: 훈련한 개체가 새 미로를 풀지 못한다는 것이 확인되었으므로 여러 미로로 번갈아 훈련하는 방식이 다음 핵심 과제이며, 센서 잡음 추가, 기억(순환) 구조, 학습과 진화의 결합 등으로 이어갈 수 있다.

한계와 후속 과제. 초기 비교는 미로·방식당 1회 실행이라 노이즈가 컸고, 반복 실험(미로 4개, 8회)으로 보완했으나 방식 간 작은 차이는 확정하지 못했다. 한 미로로만 훈련해 처음 보는 미로를 풀지 못했고, 센서 잡음과 바퀴 오차가 없는 이상적인 시뮬레이션이다. 여러 미로로 훈련, 센서 잡음과 바퀴 오차 추가, 가중치 값을 바꿔 가며 반복하는 탐색, 로봇용 코드 내보내기, 목표 위치가 바뀌는 경우, 실제 로봇 시험은 이번 연구에서 하지 못한 후속 과제이다(새 미로 100개 시험과 반복 실험은 이번에 수행했다).

참고 문헌

- [1] [논문] Floreano, D. & Mondada, F., Automatic Creation of an Autonomous Agent: Genetic Evolution of a Neural-Network Driven Robot, 1994, From Animals to Animats 3 (SAB94)
- [2] [논문] Jakobi, N., Husbands, P. & Harvey, I., Noise and the Reality Gap: The Use of Simulation in Evolutionary Robotics, 1995, Advances in Artificial Life (ECAL95), Springer, pp.704-720
- [3] [논문] Rumelhart, D. E., Hinton, G. E. & Williams, R. J., Learning representations by back-propagating errors, 1986, Nature 323(6088), pp.533-536
- [4] [논문] Yao, X., Evolving Artificial Neural Networks, 1999, Proceedings of the IEEE 87(9), pp.1423-1447

- [5] [논문] Lehman, J. & Stanley, K. O., Abandoning Objectives: Evolution through the Search for Novelty Alone, 2011, Evolutionary Computation 19(2), pp.189-223
- [6] [논문] Shorten, D. & Nitschke, G., Evolving Generalised Maze Solvers, 2015, University of Cape Town
- [7] [논문] 김대진·강대성, 진화와 학습의 상호 적응에 의한 자발적 주행 로봇을 위한 재귀 신경망 제어기 설계, 2000, 전자공학회논문지 제37권 제3호
- [8] [논문] 오동화, 게임 환경에서의 유전 알고리즘과 인공신경망을 이용한 경로탐색에 관한 연구, 2016, 한국정보처리학회 추계학술발표대회
- [9] [단행본] Holland, J. H., Adaptation in Natural and Artificial Systems, University of Michigan Press, 1975
- [10] [단행본] Braitenberg, V., Vehicles: Experiments in Synthetic Psychology, MIT Press, 1984
- [11] [단행본] Nolfi, S. & Floreano, D., Evolutionary Robotics, MIT Press, 2000
- [12] [인터넷] STMicroelectronics, VL53L0X Time-of-Flight ranging sensor, st.com, https://www.st.com/en/product/vl53l0x
- [13] [인터넷] [저자 확인 필요], Evolving Indoor Navigational Strategies Using Gated Recurrent Units In NEAT, arXiv, 2019, https://arxiv.org/abs/1904.06239