유전 로보틱스를 통한 미로 찾기 로봇

[팀명] (대표 [이름], 팀원 [이름], [이름], [이름])

1. 연구의 요약

○ 연구 동기와 목적: 로봇의 행동 규칙을 사람이 설계하는 대신 신경망의 가중치를 유전자로 두고 유전 알고리즘으로 진화시키면(유전 로보틱스) 센서 값만으로 미로를 푸는 로봇을 얻을 수 있는지 확인하고, 시뮬레이션에서 얻은 최종 가중치를 소형 실제 로봇에 넣어 보는 것을 목적으로 한다.

○ 연구 내용: 웹 시뮬레이션에서 거리 센서 5개, 은닉 뉴런 6개, 바퀴 2개 출력으로 이루어진 신경망(유전자 50개)을 개체 100마리로 진화시켰다. 가장 단순한 방식에서 시작해 실패를 관찰하고 한 번에 한 가지씩 12단계로 개선했다(충돌 감점, 이동 거리, 탐험 보상, 재방문 감점, 도착 개체 우선 정렬, 자동 조절). 이어서 지름 약 11cm의 소형 원형 로봇(아두이노 나노, N20 모터, 거리 센서 5개)을 설계해 6×6칸 미로에서 시험할 준비를 했다.

○ 발견한 점: 같은 방식이라도 미로에 따라 결과가 크게 달랐다. 탐험 보상에서 “목표와 가까운 칸” 조건을 빼자 120세대까지 풀리지 않던 미로(시드 3)가 30세대에 처음 풀렸다. 반대로 보상을 자동으로 키우는 단계 12는 미로 26만 개선하고 미로 1과 67은 풀지 못했다. 도착한 개체의 이동 거리가 최단 경로에 가까워 한 미로를 외운 해법일 가능성이 있으며, 처음 보는 미로와 실제 로봇에서의 성능은 아직 검증하지 못했다.

2. 연구 동기 및 목적

2-1. 연구 동기

평소 로봇이 스스로 판단하고 움직이는 방식에 관심이 많았다. 그러던 중 로봇의 행동 규칙을 사람이 일일이 설계하는 대신, 신경망의 가중치를 생물의 유전자처럼 다루어 세대를 거치며 진화시키는 유전 로보틱스라는 분야를 알게 되었고 매우 흥미롭게 느꼈다. 규칙을 정해 주지 않아도 점수만으로 로봇이 스스로 행동을 찾아낸다는 점이 신기했고, 직접 확인해 보고 싶었다.

이를 확인할 문제로 미로 찾기를 선택했다. 미로는 로봇이 센서로 얻은 정보만으로 길을 찾아야 하고, 성공과 실패가 분명하며, 규칙이 단순해 시뮬레이션하기 쉬운 문제이기 때문이다. 다만 실제 로봇을 수백 세대 진화시키는 것은 시간과 비용이 크므로, 컴퓨터 시뮬레이션에서 로봇을 진화시킨 뒤 최종 가중치만 소형 로봇에 넣어 실제 미로에서 시험해 보기로 했다.

2-2. 연구 목적

신경망 가중치를 유전자로 두고 유전 알고리즘으로 진화시키는 유전 로보틱스 방법으로, 사람이 규칙을 설계하지 않고도 센서만으로 미로를 찾는 로봇을 얻을 수 있는지 확인하고, 이를 소형 실제 로봇에 적용하여 시뮬레이션과 현실의 차이를 분석한다.

1. 거리 센서 5개와 작은 신경망(유전자 50개)으로 이루어진 가상 로봇이 유전 알고리즘으로 10×10칸 미로를 통과하도록 진화시킨다.
2. 가장 단순한 평가 방식에서 시작해 실패를 관찰하고, 충돌 감점·이동 거리·탐험 보상 같은 평가 항목을 한 번에 하나씩 더하며 무엇이 왜 효과가 있었는지(또는 없었는지) 분석

한다.

3. 같은 방식이 미로에 따라 얼마나 다른 결과를 내는지 확인하여 방법의 한계와 일반화 가능성을 검토한다.
4. 시뮬레이션의 최종 가중치를 지름 약 11cm의 소형 로봇(아두이노 나노, N20 모터, 거리 센서 5개)에 넣어 6×6칸 실제 미로에서 시험하고 시뮬레이션 결과와 비교한다.

3. 이론적 배경 및 선행 연구

3-1. 이론적 배경

유전 알고리즘. 생물의 진화를 흉내 낸 최적화 방법이다. 후보 해(개체)를 숫자 배열(유전자)로 나타내고, 개체마다 점수(적합도)를 매겨 점수가 높은 개체를 부모로 선택한 뒤, 유전자를 섞고(교차) 일부를 무작위로 바꾸어(돌연변이) 다음 세대를 만드는 과정을 반복한다. 본 연구는 개체 100마리, 상위 20% 보존, 한 점 교차, 돌연변이 확률 5%를 사용했다.

신경망. 입력(센서 값) → 은닉층(tanh) → 출력(바퀴 속도)으로 이어지는 계산 구조이다. 입력에 가중치를 곱해 더하고 활성화 함수를 거치는 계산이라 작은 마이크로컨트롤러에서도 돌릴 수 있다. 본 연구의 신경망은 입력 5, 은닉 6, 출력 2이며 가중치와 편향을 합친 50개가 유전자가 된다. 일반적인 신경망은 정답 데이터로 오차를 줄이며 학습하지만, 미로 주행은 매 순간의 정답 행동을 정하기 어려워 본 연구는 점수만 주고 유전 알고리즘으로 가중치를 찾았다.

유전 로보틱스. 로봇의 제어기(신경망)를 유전 알고리즘으로 자동 설계하는 분야이다. 실제 로봇에서 진화시키면 시간이 오래 걸려 시뮬레이션에서 진화시킨 뒤 실제 로봇으로 옮기는 경우가 많고, 이때 시뮬레이션과 현실의 차이(센서 잡음, 바퀴 미끄러짐, 배터리 전압 변화)가 성능 저하의 원인이 된다.

로봇 구동과 센서. 두 바퀴를 따로 돌리는 차동 구동 방식으로, 두 바퀴 속도의 평균이 전진 속도, 차이가 회전 속도가 된다. 거리는 레이저 비행시간 센서(VL53L0X, I2C 통신)로 잰다. 센서마다 기본 주소가 같아 켜기 전에 XSHUT 핀으로 하나씩 주소를 바꿔 주어야 한다.

3-2. 선행 연구

유전 로보틱스와 미로 탐색에서 알려진 문헌을 정리했다(출판 정보는 제출 전 원문으로 다시 확인해야 한다).

문헌	내용	본 연구와의 관계
Holland(1975)	유전 알고리즘의 기초 이론	선택·교차·돌연변이의 기본 구조를 사용
Braitenberg(1984)	센서를 바퀴에 직접 연결해도 복잡해 보이는 행동이 나옴	센서→바퀴의 단순한 구조를 신경망으로 확장
Floreano & Mondada(1994)	실제 Khepera 로봇에서 진화 전 과정을 돌려 장애물 회피 행동을 얻음	본 연구는 시뮬레이션에서 진화한 뒤 가중치만 이식
Shorten & Nitschke(2015)	신경 진화로 미로를 푸는 제어기를 만들고 점수 방식·새로움 탐색·혼합 방식을 비교. 새로움 탐색과 혼합 방식이 더 어려운 미로에서 일반화되는 제어기를 더 많이 만듦	“남이 안 간 칸이면 보상”을 더하자 미로 3이 풀린 본 연구 결과와 방향이 같음
arXiv 1904.06239(2019)	차동 구동 로봇이 실내 미로에서 길을 찾도록 NEAT에 GRU를 더해 진화(환경	구조까지 진화시키는 방식. 본 연구는 구조를 고정하고 가중치만 진화

	209개에서 I-Bug보다 좋은 결과)	
오동화(2016)	게임 환경에서 미로를 만들고 유전 알고리즘과 인공신경망으로 경로 탐색. 미로가 커지면 유전 알고리즘 단독은 무작위로 수렴	미로가 커질수록 어려워지는 점이 본 연구와 이어짐(실제 로봇은 아님)
김대진·강대성(2000)	Khepera의 재귀 신경망 제어기를 진화와 학습을 함께 써서 설계, 진화만 쓴 경우보다 충돌 회피 우수	본 연구는 진화만 사용. 학습 결합은 후속 과제

국내 선행 연구는 추가 조사하여 보완한다.

4. 연구 과정 및 방법

4-1. 연구 과정

실험 환경과 용어

실험은 컴퓨터 속 가상 미로에서 로봇 100대가 동시에 출발하는 방식으로 진행했다. 미로는 한 변 10칸, 한 칸 20cm이고 오른쪽 위 칸에서 출발해 왼쪽 아래 칸에 들어가면 성공이다. 로봇은 지름 8cm의 원이며 로봇이 향한 방향 기준 왼쪽, 왼쪽 앞, 앞, 오른쪽 앞, 오른쪽의 벽까지 거리(최대 40cm)를 재는 센서 5개를 가진다. 100대가 40초 동안 움직이면 한 세대가 끝나고 점수가 높은 로봇을 바탕으로 다음 세대 100대를 만든다.

용어	뜻
개체 / 유전자	개체는 가상 로봇 한 대이며, 신경망 가중치와 편향 50개의 숫자가 그 개체의 유전자이다
세대 / 적합도	세대는 100대가 한 번 달리고 점수를 받는 한 회차, 적합도는 한 대가 얼마나 잘했는지 나타내는 점수이다
시드(미로 번호)	미로를 만드는 난수의 번호. 같은 번호이면 같은 미로와 같은 처음 로봇이 만들어져 결과를 재현할 수 있다. 본 연구는 1, 2, 3, 26, 67번으로 실험했다
도착 / 충돌	도착은 로봇 중심이 목표 칸에 들어가는 것, 충돌은 몸체가 벽과 겹쳐 밀려나는 것(0.05초마다 판정)이다
칸 단위 최단 경로	출발 칸에서 목표 칸까지 벽을 통과하지 않고 가는 최소 칸 수 × 20cm. 로봇은 모서리를 자를 수 있어 이보다 짧은 기록도 나온다
탐험 보상	도착하지 못한 로봇이 다른 로봇이 가지 않은 칸을 방문하면 점수를 더해 주는 요소
재방문 / 정체	재방문은 이미 지난 칸에 다시 들어가는 것, 정체는 최고 기록이 여러 세대 동안 거의 나아지지 않는 상태이다
순위 역전 / 도착 개체 우선 정렬	순위 역전은 도착하지 못한 로봇의 점수가 도착한 로봇보다 높아지는 현상, 우선 정렬은 도착한 로봇을 점수와 관계없이 항상 위에 두어 부모로 보존하는 방식이다

4-1-1. 연구 진행 일정

본 연구는 완성된 알고리즘을 한 번에 설계하지 않고, 가장 단순한 방식에서 시작해 실패를 관찰하고 문제를 하나씩 개선하는 순서로 진행했다. 알고리즘은 개체(센서·신경망·움직임), 평가(적합도 계산), 진화(선택·교차·돌연변이)의 세 부분으로 나누어 각 단계에서 어느 부분을 바꾸었는지 구분했고, 개선할 때마다 이전 방식은 수정하지 않고 보존했다.

(1) 기본 방식의 설정 (단계 1~3: 개체)

단계 1. 칸 단위로 이동하고 벽의 유무(0 또는 1)를 알려 주는 센서 4개를 사용했으며 적합도는 종료 위치와 목표 사이 직선거리에 음의 부호를 붙인 값(f = −d)으로 했다. 약 50세대

까지 도착 개체가 없었고 최고 개체도 벽에 막혀 정지했다. 벽의 유무만 알려 주는 센서는 정보량이 부족하다고 판단했다.

단계 2. 연속 이동과 로봇이 향한 방향 기준 거리 센서 5개, 두 바퀴 출력으로 개체를 바꾸었다. 25세대까지는 도착이 없었으나 40세대에 미로 1, 2, 3 모두에서 도착 개체(44~70마리)가 나타났다. 이후 모든 실험은 이 방식을 기본으로 했다.

단계 3. 센서 배치의 영향을 보기 위해 상하좌우 방향이 고정된 센서 4개와 4방향 이동 방식을 추가했다. 이 방식은 25세대 동안 최고 적합도가 변하지 않았고 벽 충돌이 733회였다. 센서와 이동 방식이 함께 달라 센서만의 우열로 해석하지 않았다.

(2) 적합도 계산식의 개선 (단계 4~12: 평가, 단계 9는 평가·진화)

단계	변경한 적합도 계산식	변경 사유	관찰 결과
4	벽에 부딪힌 횟수 b에 감점 p를 곱해 감산	벽에 반복 충돌하며 이동하는 개체가 다수	감점 0.5~1.0에서 충돌 거의 없이 도착(미로 1), 감점 0.2는 미로 1·3에서 도착 못함
5	도착 개체는 200 − (이동 거리 가중치 × 이동 거리 L)	도착해도 우회 경로가 김	미로 1의 이동 거리 570→466cm, 도착 개체 수는 감소
6	충돌 감점과 이동 거리를 병용	두 요소를 함께 썼을 때의 영향 확인	미로에 따라 감점 0.2와 0.5의 우열이 반대, 미로 3은 모두 실패
7	목표와 가까운 칸에 가중한 탐험 보상 N 추가(단계 2에서 분기)	막다른 구역에 갇힌 개체가 탈출하지 못함	순위 역전 발생, 미로 26·3에서 도착 감소
8	충돌 감점·이동 거리·탐험 보상을 하나로 통합	이전 기능을 누적하기 위함	미로 26에서 충돌 5회로 감소, 미로 3은 실패
9	도착 개체를 점수와 관계없이 상위 정렬, 도착 후 탐험 보상 종료와 재방문 감점 r 적용	순위 역전과 도착 후 불필요한 탐험	미로 26·1·2에서 도착 개체 증가, 미로 3은 변화 없음
10	탐험 보상에서 “목표에 가까운 칸” 조건 제거	보상이 목표 근처 막다른 구석에 편중된 것으로 추정	미로 3이 30세대에 처음 도착
11	도착 후 최단 이동 거리가 정체되면 이동 거리 배율 m을 단계적으로 증가	도착 후 경로가 더 짧아지지 않음	미로 26의 최소 이동 682→524cm, 나머지는 거의 변화 없음
12	탐험 보상 상한 해제, 충돌 감점의 자동 조절	가중치를 사람이 정하지 않고 진행 상태에 맞춰 조절하는 방식의 효과 확인	미로 26만 개선, 미로 1·67은 도착 못함, 미로 2·3은 악화

단계 7은 단계 6이 아니라 단계 2의 기본 방식에서 분기했고 단계 8에서 앞의 요소를 모두 통합했다. 12단계 중 개체를 바꾼 단계는 2, 3이고 진화(정렬 방식)를 바꾼 단계는 9이며 나머지는 모두 평가(적합도 계산식)의 개선이다. 최종 단계(단계 12)의 적합도는 다음과 같다.

미도착 개체: $f = -d - p \cdot b + w_{탐험} \cdot N$

도착 개체: $f = 200 - w_{거리} \cdot m \cdot L - p \cdot b - r \cdot R$

기호	이름	정의 및 값
f	적합도	개체의 우수성을 나타내는 점수. 클수록 부모로 선택될 가능성이 높다
d	종료 거리	종료 시점(미도착은 40초 경과 시점)에서 로봇 중심과 목표 칸 중심 사이의 직선거리(cm)

b, p	충돌 횟수, 충돌 감점	제어 주기(0.05초)마다 몸체가 벽과 겹쳐 밀려난 횟수, 1회당 감점(기본 0.2). 단계 12에서는 진행 상태에 따라 0~0.6으로 자동 변화
N	새로움 점수	개체가 방문한 각 칸에 대해 그 칸을 방문한 개체 수의 역수를 합한 값. 소수의 개체만 가 본 칸을 방문할수록 커진다(단계 7~9는 칸마다 “목표와 가까운 정도” 곱함)
w탐험	탐험 보상 가중치	0에서 시작해 최단 거리가 5세대 동안 3cm 넘게 줄지 않으면 최댓값(기본 10, 단계 12는 100)의 1/4씩 증가, 거리가 줄면 0으로 복귀. 도착 개체에는 부여하지 않음
L, w거리, m	이동 거리, 가중치, 배율	도착 개체의 실제 이동 거리(cm), 이동 거리 가중치(0.1), 최소 이동 거리가 5세대 동안 5cm 넘게 줄지 않으면 1씩 증가하는 배율(1~9)
R, r	재방문 횟수, 재방문 감점	이미 지난 칸에 다시 들어간 횟수, 1회당 감점(1). 도착 개체가 처음 나온 다음 세대부터 적용
200	도착 기본 점수	도착한 개체가 미도착 개체보다 항상 높은 점수를 갖도록 하는 기준값

(3) 실제 로봇 적용을 위한 준비

① 제작 가능한 크기의 현실용 설정(6×6칸 미로, 칸 25cm, 로봇 지름 11cm)을 추가했다. 기존 연구용 설정(10×10칸)은 바꾸지 않았고 동일 조건(미로 1, 25세대)에서 이전과 같은 결과가 재현됨을 확인했다.

② 소형 원형 로봇을 설계하고 부품을 선정했다(아두이노 나노, N20 모터와 지름 34mm 바퀴, TB6612 모터 드라이버, VL53L0X 센서 5개, AAA 전지 3개와 5V 승압 모듈). 구상도와 배선도를 작성했다(그림 1, 2).

③ 6×6칸 미로 시드 1~400 중 최단 경로 16칸 이상, 막다른 길 6개 이상, 최단 경로상 갈림길 4개 이상인 38개를 골랐다(상위 후보: 시드 365, 350, 80, 178).

④ (예정) 후보 시드에서 현실용 설정으로 학습시켜 도착 여부를 확인하고 최종 가중치를 정한다. ⑤ (예정) 로봇을 제작하고 센서 주소 설정, 신경망 계산, 모터 제어 펌웨어를 작성한다. ⑥ (예정) 실제 미로에서 시험하고 시뮬레이션 결과와 비교한다.

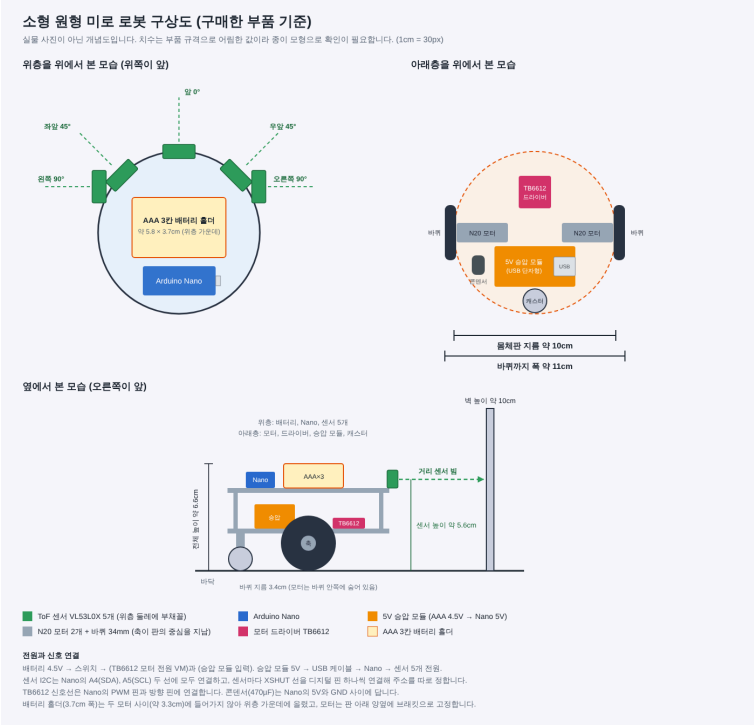


그림 1. 소형 원형 로봇 구상도(위층·아래층·옆면)

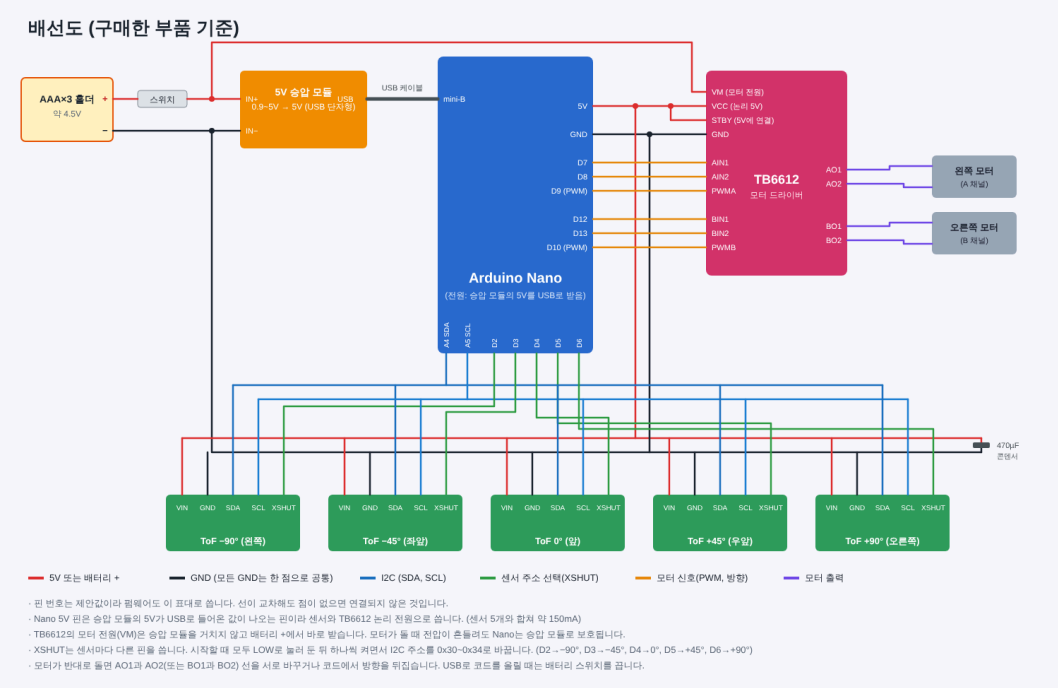


그림 2. 배선도(전원, 승압 모듈, 나노, 모터 드라이버, 거리 센서 5개)

4-2-1. 가설 설정, 실험설계 및 과정, 분석방법, 시행착오 극복

① 가설 설정

1) 신경망 가중치를 유전자로 쓰는 유전 알고리즘만으로, 미로 규칙을 정해 주지 않아도 거리 센서만 보는 로봇이 미로를 통과하도록 진화한다.
2) 점수(적합도)에 보상·감점 항목을 한 번에 하나씩 더하면 풀리는 미로가 늘고 도착 경로가 짧아진다.
3) 시뮬레이션에서 얻은 최종 가중치를 같은 센서 배치의 소형 실제 로봇에 넣어도 비슷하게 동작한다(실제 시험으로 확인 예정).

② 실험 설계 및 과정

신경망. 로봇의 행동은 하나의 신경망이 결정한다. 입력은 센서 5개의 거리를 최대 측정 거리 40cm로 나눈 0~1의 값, 은닉 뉴런은 6개, 출력은 왼쪽·오른쪽 바퀴 속도(−1~1)이다. 뉴런은 입력에 가중치를 곱해 합하고 편향을 더한 뒤 tanh를 적용한다.

은닉 $h_j = \tanh(\Sigma w_{ij} \cdot x_i + b_j)$, 출력 $o_k = \tanh(\Sigma v_{jk} \cdot h_j + c_k)$

유전자 수 = 5×6 + 6 + 6×2 + 2 = 50

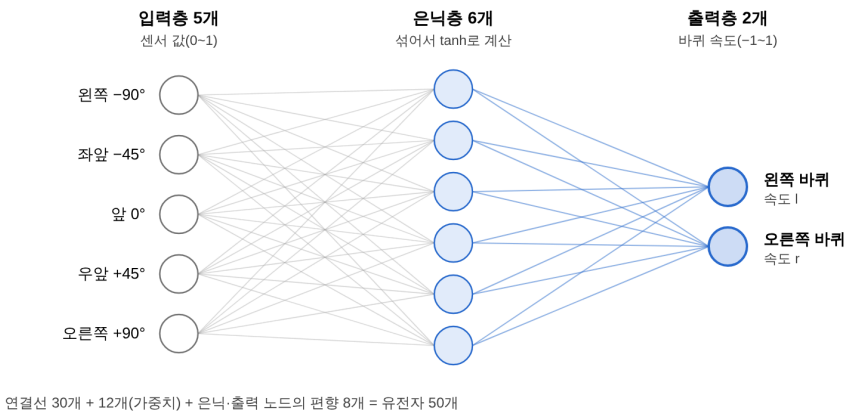


그림 3. 신경망 구조(입력 5, 은닉 6, 출력 2)

계산 예(설명용 가상 값): 센서 값 x = (0.9, 0.7, 0.2, 0.7, 0.9)(앞 센서 0.2는 약 8cm 앞에 벽), 한 은닉 뉴런의 가중치 (0.5, −0.3, −1.2, 0.4, 0.1)와 편향 0.1이면 0.9×0.5+0.7×(−0.3)+0.2×(−1.2)+0.7×0.4+0.9×0.1+0.1 = 0.47이므로 h = tanh(0.47) ≈ 0.44이다. 출력 l = 0.41, r = −0.86이 나왔다면 전진 속도 (l+r)/2×30 ≈ −6.8cm/s, 회전 속도 (l−r)×30/8 ≈ 4.8rad/s로 로봇은 약간 후진하며 오른쪽으로 빠르게 회전한다(최고 속도 30cm/s, 바퀴 간격 8cm). 이 계산을 0.05초마다 최대 800회(40초) 반복한다.

적합도 지정. 개체 100개를 같은 미로의 출발 칸에서 동시에 출발시켜 최대 40초 움직이게 하고, 최초의 적합도는 종료 위치와 목표 칸 중심 사이의 직선거리 d(cm)에 음의 부호를 붙인 f = −d로 정의했다. 목표 칸에 진입하면 도착으로 판정해 그 자리에서 멈춘다. 적합도는 정답 행동을 알려 주지 않고 결과의 우수성만 나타낸다.

우수 유전자 선택과 돌연변이. 적합도 상위 20%(20개체)를 부모로 삼아 유전자를 변경 없이 다음 세대에 그대로 넘긴다. 나머지 80개체는 부모 둘을 무작위로 골라 유전자 50개를 임의의 한 지점에서 자르고 앞부분은 한 부모, 뒷부분은 다른 부모에서 가져와 만들며(한 점 교차), 자식 유전자의 각 원소에 5% 확률로 평균 0, 표준편차 0.5의 난수를 더한다(돌연변이). 이 과정을 100~250세대 반복한다. 처음 개체의 유전자는 평균 0, 표준편차 1의 난수로 만든다.

적합도 계산식의 단계적 변경. 신경망 구조와 진화 규칙은 고정하고 적합도 계산식만 바꾸며 영향을 비교했다. 이전 단계에서 본 문제를 근거로 요소를 한 번에 하나씩만 더하거나 고치고, 이전 방식은 수정하지 않고 보존하며, 결과가 나빠져도 값을 임의로 고치지 않고 그대로 기록했다. 단계별 내용은 4-1-1에 기술했다.

변인 통제. 신경망 구조, 개체 수 100, 상위 20% 보존, 한 점 교차, 돌연변이 5%(크기 0.5), 로봇 크기·최고 속도(30cm/s)·센서 개수와 측정 범위, 제어 주기 0.05초, 한 세대 40초, 출발·도착 위치를 모든 실험에서 같게 했다. 난수열은 시드로 고정해 같은 번호에서는 같은 미로와 같은 처음 개체가 나오게 했다. 독립변인은 평가 방식(단계 1~12), 미로 번호(1, 2, 3, 26, 67), 감점·보상 가중치이고 종속변인은 마지막 세대의 도착 개체 수, 첫 도착 세대, 도착 개체의 최소 이동 거리, 충돌 횟수이다.

③ 분석 방법

세대마다 도착 개체 수, 최고 개체의 목표까지 거리, 충돌 횟수, 이동 거리를 기록해 단계별·미로별로 비교했다. 도착 개체의 이동 거리는 칸 단위 최단 경로와 비교했다. 미로마다 방식당 1회씩 실행했으므로 작은 차이는 유의한 차이로 해석하지 않았고, 수치로 직접 본 결과(확인)와 원인을 분리해 검증하지 못한 해석(추정)을 구분해 기술했다.

④ 시행착오와 극복

문제	원인	해결
단계 1에서 50세대까지 도착 없음	칸 단위 이동과 벽 유무 센서는 정보가 부족	연속 이동과 방향 기준 거리 센서 5개로 변경(단계 2)
탐험 보상 후 도착 개체보다 미도착 개체의 점수가 높아짐(미로 26, 50세대: −5.5 대 −9.4)	탐험 보상이 도착 보상을 넘음	도착 개체를 점수와 관계없이 위에 정렬(단계 9)
미로 3이 120세대까지 풀리지 않음	보상이 목표 근처 막다른 구석에 쏠린 것으로 추정	“목표와 가까움” 조건 제거(단계 10), 30세대에 해결

단계 12가 일부 미로에서 악화	도착 뒤 충돌 감점이 0.6까지 올라 이동 거리보다 크게 작용한 것으로 추정	값을 임의로 고치지 않고 결과를 그대로 기록, 일반화는 후속 과제
연구용 미로(10×10칸, 20cm)는 실제로 만들기에 큼	실제 미로와 로봇을 만들 수 없는 크기	연구용 설정은 두고 현실용 설정(6×6칸, 25cm, 지름 11cm) 추가

5. 연구 결과 및 고찰

5-1-1. 연구 과정 요약, 실험 결과 및 연구 결론

연구 과정 요약. 가장 단순한 방식(단계 1)에서 시작해 단계마다 한 가지 요소만 더하며 12단계까지 올렸다. 앞 단계에서 드러난 문제를 다음 단계의 개선 대상으로 삼았고, 개선이 오히려 악화를 가져와도 임의로 고치지 않고 그대로 기록했다.

미로별 도착 개체 수. 단계 8~12를 미로 5개에서 1회씩 실행했다(단계 8~11은 120세대, 단계 12는 150세대). 각 칸은 “마지막 세대의 도착 개체 수(첫 도착 세대)”이다. 미로 67은 단계 8, 9, 11을 실행하지 않았다.

미로	단계 8	단계 9	단계 10	단계 11	단계 12
26	34 (20)	43 (20)	32 (15)	33 (15)	46 (7)
1	27 (57)	34 (57)	32 (67)	34 (67)	0 (없음)
2	40 (7)	49 (7)	49 (7)	45 (7)	46 (7)
3	0 (없음)	0 (없음)	28 (30)	29 (30)	2 (113)
67	-	-	0 (130세대)	-	0 (없음)

미로 67은 단계 10에서 탐험 보상 최댓값을 기본값 10 대신 30으로 설정하면 약 91세대에 목표까지 거리가 74cm에서 60cm 아래로 내려가 정체를 벗어났고 152세대에 처음 도착했다(250세대에 28마리).

도착한 개체의 최소 이동 거리(cm). 칸 단위 최단 경로와 함께 적었다. 로봇이 모서리를 자를 수 있어 최단 경로보다 짧은 값도 나온다.

미로	칸 단위 최단 경로	단계 10	단계 11	단계 12
26	560	682	524	527
1	440	493	499	도착 못함
2	400	356	365	487
3	560	696	690	856

실험 결과에서 알아낸 것.

○ 확인: 같은 방식도 미로에 따라 결과가 크게 달랐다. 단계 12는 미로 26에서 7세대에 도착했지만 미로 1에서는 150세대까지 도착하지 못했다.

○ 확인과 추정: 탐험 보상에서 “목표와의 가까움” 조건을 빼자 미로 3이 풀렸다(미로 하나, 1회). 직선거리로 목표에 가까운 막다른 구석에 보상이 쏠려 우회로가 불리해졌기 때문으로 보이나 원인을 직접 분리하지는 못했다. 탐험 가중치를 75~100까지 올린 단계 12에서는 목표까지 거리가 오히려 멀어지는 구간이 있어 거리 신호가 흐려진 것으로 보인다(추정).

○ 확인과 추정: 자동 조절(단계 12)은 미로 26만 개선했고 미로 2의 최소 이동 거리는 365cm에서 487cm로 늘었다. 도착 뒤 충돌 감점이 0.6까지 오른 영향으로 보인다(추정).

○ 추정: 도착 개체의 이동 거리가 최단 경로에 가까워(미로 1: 493~499cm, 최단 440cm) 훈련한 한 미로를 외운 해법일 가능성이 있다. 처음 보는 미로에서의 성공률을 재지 못해 확정하지 못했다.

현실용 미로와 실제 로봇. 6×6칸 현실용 미로에서 최단 경로가 16칸 이상이고 막다른 길과 갈림길이 많은 시드를 1~400 중에서 찾았다(조건 충족 38개, 상위 후보 365, 350, 80, 178). 이 시드에서의 학습 결과와 실제 로봇 시험 결과는 아래에 채워야 한다.

항목	결과
현실용 설정에서 학습 결과(후보 시드별 도착 여부)	[실험 후 기입]
실제 로봇 성공 횟수 / 시도 횟수	[실험 후 기입]
시뮬레이션과 실제의 경로·소요 시간 차이	[실험 후 기입]

연구 결론.

1) 거리 센서만 보는 작은 신경망(유전자 50개)을 유전 알고리즘으로 진화시켜 시뮬레이션에서 미로를 푸는 로봇이 여러 미로에서 나왔다. 이때 벽 따라가기 같은 규칙은 넣지 않았다.

2) “목표에 가까울수록 좋다”는 단순한 평가만으로는 미로에 따라 실패했고, 충돌·이동 거리·탐험 같은 평가 항목을 하나씩 더하자 풀리는 미로가 늘었다. 다만 항목마다 새로운 부작용이 나타나 다음 단계의 개선 대상이 되었다.

3) 자동 조절은 기대한 만큼 효과가 없었고 결과는 미로에 크게 좌우되었다. 이 연구의 결과는 “가능성의 확인”이며 일반화는 아직 보이지 못했다.

4) 실제 로봇에서의 결과는 실험 후 이 항목에 추가한다.

5-2-1. 국내외 연구 사례와의 비교 분석

로봇의 신경망 제어기를 진화시키는 연구는 많다. 미로 주행·장애물 회피와 직접 관련된 사례를 검색으로 찾아 본 연구와 비교했다(세부 수치와 방법은 원문을 확인해 보완해야 한다).

연구	대상과 방법	본 연구와의 비교
Shorten & Nitschke(2015)	신경 진화로 미로 제어기 생성, 점수 방식·새로움 탐색·혼합 비교. 새로움 탐색과 혼합 방식이 더 큰 미로에 일반화되는 제어기를 더 많이 만듦	점수 방식이 막히면 새로운 칸 보상을 더해 미로 3을 풂. 처음 보는 미로 일반화는 본 연구가 아직 못 잼
arXiv 1904.06239(2019)	차동 구동 로봇의 실내 미로 주행을 NEAT+GRU로 진화(환경 209개)	구조까지 진화. 본 연구는 구조를 고정해 변인을 줄임
Floreano & Mondada(1994)	실제 Khepera 로봇에서 진화 전 과정을 사람 개입 없이 수행	본 연구는 시뮬레이션 진화 후 가중치만 이식. 시뮬레이션과 현실의 차이 확인 필요
오동화(2016)	게임 환경에서 미로를 만들어 유전 알고리즘과 신경망으로 경로 탐색	미로가 커질수록 어려운 점이 본 연구와 이어짐. 실제 로봇은 아님
김대진·강대성(2000)	Khepera 재귀 신경망 제어기를 진화와 학습을 함께 써서 설계	본 연구는 진화만 사용. 학습 결합은 후속 과제

비교를 통해 알 수 있는 점은 다음과 같다. 첫째, 새로움을 보상하는 방향은 선행 연구와 같다. 둘째, 선행 연구는 여러 미로에서 성능을 재는 일반화를 중심에 두는데 본 연구는 훈련한 미로에서만 평가했다. 셋째, 시뮬레이션에서 진화해 실제 로봇으로 옮기는 점이 차별점이자 위험 요소이며, 센서 잡음과 바퀴 미끄러짐을 학습에 넣지 않았으므로 실제 시험이 중요하다. 넷째, 완성된 결과가 아니라 단계마다의 실패와 부작용(순위 역전, 보상 쏠림, 자동 조절의 악화)을 기록한 것이 본 연구의 특징이다.

5-2-2. 기대 효과

1) 교육적 효과: 유전 알고리즘·신경망·로봇 제어를 하나의 프로젝트로 엮어 학생 수준에서 재현할 수 있는 웹 시뮬레이터와 제작 절차를 제공한다.
2) 실패 기록의 가치: 점수 항목을 하나씩 더할 때 생기는 부작용을 기록해 후속 연구자가 같은 시행착오를 줄일 수 있다.
3) 저비용 실제 적용: 시뮬레이션에서 얻은 가중치만 로봇에 넣으므로 실제 로봇을 수백 세대 돌리지 않아도 되고, 부품도 아두이노 나노와 N20 모터 같은 저렴한 것(10만 원 안쪽)을 쓴다.
4) 후속 연구의 출발점: 새 미로에서의 일반화 측정, 여러 미로로 훈련, 센서 잡음 추가, 기억(순환) 구조, 학습과 진화의 결합 등으로 이어갈 수 있다.

한계와 후속 과제. 미로마다 방식당 1회씩만 실행해 노이즈가 크고 작은 차이는 확정하지 못했다. 훈련과 평가를 같은 미로에서 했고 센서 잡음과 바퀴 오차가 없는 이상적인 시뮬레이션이다. 새 미로 100개 시험, 여러 미로로 훈련, 센서 잡음과 바퀴 오차 추가, 가중치 값을 바꿔 가며 반복하는 탐색, 로봇용 코드 내보내기, 목표 위치가 바뀌는 경우는 이번 범위에서 제외한 후속 과제이다.

참고 문헌

- [논문] Shorten, D. & Nitschke, G., Evolving Generalised Maze Solvers, 2015, University of Cape Town
- [논문] 오동화, 게임 환경에서의 유전 알고리즘과 인공신경망을 이용한 경로탐색에 관한 연구, 2016, 한국정보처리학회 추계학술발표대회
- [논문] 김대진·강대성, 진화와 학습의 상호 적응에 의한 자발적 주행 로봇을 위한 재귀 신경망 제어기 설계, 2000, 전자공학회논문지 제37권 제3호
- [논문] Floreano, D. & Mondada, F., Automatic Creation of an Autonomous Agent: Genetic Evolution of a Neural-Network Driven Robot, 1994, From Animals to Animats 3
- [논문] Gomes, J. & Christensen, A., Comparing Approaches for Evolving High-Level Robot Control Based on Behaviour Repertoires, 2018, IEEE CEC
- [단행본] Holland, J. H., Adaptation in Natural and Artificial Systems, University of Michigan Press, 1975
- [단행본] Braitenberg, V., Vehicles: Experiments in Synthetic Psychology, MIT Press, 1984
- [단행본] Nolfi, S. & Floreano, D., Evolutionary Robotics, MIT Press, 2000
- [인터넷] [저자 확인 필요], Evolving Indoor Navigational Strategies Using Gated Recurrent Units In NEAT, arXiv, 2019, https://arxiv.org/abs/1904.06239

- [인터넷] Floreano & Mondada 원문, ETH Research Collection, 1994, https://www.research-collection.ethz.ch/bitstream/handle/20.500.11850/82611/1/eth-8405-01.pdf